



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

# **Quantum Machine Learning vs Machine Learning Tradizionale: Una Revisione Sistemática della Letteratura**

RELATORE

Prof. Andrea De Lucia

Dott. Fabiano Pecorelli

Università degli Studi di Salerno

CANDIDATO

**Luigi De Chiara**

Matricola: 0512109483

Anno Accademico 2022-2023

*Questa tesi è stata realizzata nel*

sesa<sup>lab</sup>  
SOFTWARE ENGINEERING  
SALERNO

*“La felicità la puoi trovare anche nei momenti più bui.*

*Devi solo ricordarti di accendere la luce”.*

*(Sirius Black)*

## **Abstract**

Il Quantum Machine Learning (QML) è un campo emergente che combina principi del Machine Learning (ML) con quelli della meccanica quantistica. La sua promessa di sfruttare le peculiarità dei computer quantistici per risolvere complessi compiti di apprendimento ha attirato l'attenzione della comunità scientifica. Questo studio presenta una revisione sistematica della letteratura per identificare le principali differenze nella pipeline del QML rispetto al ML tradizionale. Sono state analizzate fonti accademiche, articoli di ricerca e conferenze di rilievo per individuare gli aspetti fondamentali che caratterizzano entrambe le metodologie. Questo studio vuole validare la nostra ipotesi che il QML presenta differenze significative nella fase di preparazione dei dati, nella progettazione degli algoritmi, nella fase di addestramento dei modelli e nelle valutazioni delle prestazioni. La comprensione di queste differenze può aiutare i ricercatori e gli sviluppatori a trarre vantaggio da entrambe le metodologie, accelerando così l'avanzamento delle applicazioni di QML.

---

# Indice

---

<b>Elenco delle Figure</b>	<b>iii</b>
<b>Elenco delle Tabelle</b>	<b>v</b>
<b>1 Introduzione</b>	<b>1</b>
1.1 Contesto Applicativo . . . . .	1
1.2 Motivazioni e Obiettivi . . . . .	2
1.3 Struttura della tesi . . . . .	3
<b>2 Background e Stato dell'arte</b>	<b>4</b>
2.1 Introduzione al Quantum Computing . . . . .	5
2.1.1 Qubit . . . . .	5
2.1.2 Superposition . . . . .	6
2.1.3 Entanglement . . . . .	6
2.2 Introduzione al Machine Learning . . . . .	7
2.2.1 Modelli di Machine Learning . . . . .	8
2.3 Pipeline di Machine Learning . . . . .	9
2.4 QML: Un'Integrazione Rivoluzionaria tra Computazione Quantistica e Apprendimento Automatico . . . . .	13
<b>3 Attività Di Ricerca: Metodologia e Strumenti</b>	<b>17</b>

---

3.1	Revisione sistematica della letteratura . . . . .	17
3.2	Descrizione del problema di ricerca . . . . .	18
3.3	Protocollo di ricerca bibliografica . . . . .	20
3.4	Definizione delle strighe di ricerca . . . . .	21
3.5	Definizione dei criteri di inclusione\esclusione . . . . .	23
3.6	Valutazione della qualità . . . . .	24
3.7	Estrazione dei dati . . . . .	24
<b>4</b>	<b>Risultati</b>	<b>27</b>
4.1	Esecuzione del processo di ricerca . . . . .	27
4.2	Analisi dei risultati . . . . .	29
4.3	La pipeline nel Machine Learning Quantistico . . . . .	31
4.4	Differenze nella pipeline del QML rispetto al Machine Learning tradi- zionale . . . . .	38
4.4.1	Preparazione dei dati nel QML . . . . .	39
4.4.2	Addestramento dei modelli nel QML . . . . .	41
4.4.3	Valutazione delle prestazioni nel QML . . . . .	46
4.4.4	Ottimizzazione dei parametri nel QML . . . . .	48
<b>5</b>	<b>Conclusioni e Sviluppi Futuri</b>	<b>51</b>
5.1	Punti critici e Direzioni future . . . . .	52
	<b>Bibliografia</b>	<b>54</b>

---

## Elenco delle figure

---

2.1	QML. . . . .	4
2.2	Types of ML. . . . .	8
2.3	Pipeline di Machine Learning. . . . .	10
2.4	Algoritmo di Shor. . . . .	14
2.5	Algoritmo di ricerca di Grover. . . . .	15
4.1	Rappresentazione del processo di selezione degli studi. . . . .	28
4.2	Numero di articoli pubblicati nel corso degli anni. . . . .	29
4.3	Percentuale di conference e journal degli articoli selezionati. . . . .	30
4.4	Numero di articoli analizzati per ogni fase. . . . .	33
4.5	Numero di articoli pubblicati nel corso degli anni per la fase di preparazione dei dati. . . . .	35
4.6	Numero di articoli pubblicati nel corso degli anni per la fase di addestramento dei moodelli. . . . .	36
4.7	Numero di articoli pubblicati nel corso degli anni per la fase di valutazione delle prestazioni. . . . .	36
4.8	Numero di articoli pubblicati nel corso degli anni per la fase di ottimizzazione dei parametri. . . . .	37
4.9	QML vs ML. . . . .	38
4.10	Quantum data processing: QML. . . . .	39

4.11 Vista schematica dell'algoritmo VQC. . . . .	42
4.12 Matrici e Rappresentazioni Circuituali dei Gate X, CNOT, RY e ROT. .	43
4.13 Classification QML algorithms . . . . .	45



---

## Elenco delle tabelle

---

3.1	Step Systematic Literature Review. . . . .	18
4.1	Elenco delle fonti per ogni fase . . . . .	34

# CAPITOLO 1

---

## Introduzione

---

### 1.1 Contesto Applicativo

Nel corso degli ultimi tre decenni, abbiamo assistito a un'accelerazione strabiliante della tecnologia informatica, con processori sempre più potenti che hanno trasformato radicalmente il modo in cui affrontiamo le sfide computazionali. Tuttavia, nonostante i considerevoli progressi, ci troviamo di fronte a problemi sempre più complessi che richiedono soluzioni innovative. Sebbene attendere la prossima generazione di processori possa sembrare una strategia logica, scopriamo che per molte sfide, la semplice escalation della potenza di elaborazione tradizionale potrebbe non essere sufficiente.

Immaginiamo di dover ordinare un elenco di un miliardo di numeri in un secondo: una sfida che richiederebbe una CPU ben oltre il livello attuale. Questo ci fa riflettere sul concetto che "di più è anche diverso". Ecco dove entrano in gioco i computer quantistici. Sebbene possano operare a velocità inferiori rispetto ai loro omologhi classici, la loro vera potenza emerge nella capacità di affrontare problemi complessi in modo radicalmente diverso, grazie alle peculiarità della meccanica quantistica [1].

Negli ultimi anni, con il progresso tecnologico imminente, la convergenza tra il mondo quantistico e l'intelligenza artificiale ha dato vita a una nuova disciplina: il

Quantum Machine Learning (QML).

Questa disciplina fonde principi della meccanica quantistica con le potenzialità dell'apprendimento automatico. L'integrazione di componenti quantistiche nel processo di apprendimento automatico apre le porte a una nuova era, dove le sfide computazionali intricate possono essere affrontate con maggiore efficacia, superando i limiti degli approcci tradizionali.

Il QML si configura come una chiave fondamentale per aprire nuovi orizzonti nella computazione avanzata, offrendo opportunità senza precedenti per la ricerca scientifica e l'innovazione tecnologica.

Uno studio recente condotto da MarketDigits proietta il mercato dell'informatica quantistica verso una straordinaria crescita, prevedendo un raggiungimento di 4.456,0 milioni di dollari entro il 2030, con una previsione di crescita composta annua (CAGR) del 24,2% nel periodo compreso tra il 2023 e il 2030. Questi dati sottolineano l'entusiasmante potenziale di questa tecnologia emergente, mentre evidenziano anche l'imperativo di comprendere appieno le sue implicazioni e le sue sfide [2].

## **1.2 Motivazioni e Obiettivi**

I recenti progressi nella tecnologia quantistica, come la realizzazione di computer quantistici e l'accessibilità crescente a hardware correlato, hanno catturato l'attenzione di numerosi esperti, ponendo particolare attenzione all'ambito dell'elaborazione dei dati.

L'obiettivo primario di questo studio è fornire delle linee guida chiare e approfondite per coloro che desiderano immergersi in queste discipline.

Saranno esaminati in dettaglio concetti fondamentali dell'apprendimento automatico quantistico, sottolineando come essi si discostino in modo significativo dall'apprendimento automatico classico.

Un aspetto distintivo di questa ricerca è l'intento di individuare e illustrare in modo esaustivo le principali differenze nella pipeline del QML rispetto a quella del ML tradizionale. Quest'analisi mira a fornire una comprensione completa delle peculiarità della metodologia quantistica e di come queste influenzino in modo sostanziale la gestione e l'elaborazione dei dati rispetto ai metodi convenzionali.

## 1.3 Struttura della tesi

La presente tesi è strutturata in cinque capitoli, ciascuno dedicato a un aspetto specifico della ricerca:

1. **Introduzione:** Questo capitolo fornisce una panoramica generale del lavoro svolto, introducendo il contesto e gli obiettivi della tesi.
2. **Background e Stato dell'arte:** In questo capitolo, verrà esaminato lo stato attuale della conoscenza nel campo di studio, concentrando l'attenzione sui concetti di QML e sulle pipeline. Sarà un'analisi approfondita della letteratura pertinente.
3. **Attività di Ricerca: Metodologia e Strumenti:** Questo capitolo dettaglia la metodologia utilizzata per condurre la revisione sistematica della letteratura (SLR). Si discuterà la formulazione della domanda di ricerca e le motivazioni che l'hanno guidata.
4. **Risultati:** In questo capitolo, saranno presentati e discussi i risultati ottenuti dalla ricerca condotta. Si analizzeranno le scoperte chiave e le loro implicazioni.
5. **Conclusioni:** Il capitolo conclusivo affronterà i punti critici emersi durante la ricerca e delinea le direzioni future.

## CAPITOLO 2


---

### Background e Stato dell'arte

---

Il presente capitolo si propone di fornire un approfondimento sul background e lo stato dell'arte su Quantum Machine Learning (QML) e Machine Learning tradizionale. Si procederà con un'analisi approfondita del concetto di pipeline di Machine Learning, delineandone le fasi.

Inoltre verrà fornita una panoramica dei punti salienti relativi al Quantum Computing (Figura 2.1).



**Figura 2.1:** QML.

## 2.1 Introduzione al Quantum Computing

Il Quantum Computing costituisce una delle frontiere più all'avanguardia e affascinanti nel campo della ricerca informatica. Nasce dalla fusione di principi fondamentali della meccanica quantistica con la teoria dell'informazione, offrendo un paradigma di calcolo radicalmente diverso rispetto ai computer classici. Questa nuova disciplina promette di rivoluzionare il modo in cui affrontiamo problemi computazionali complessi, introducendo concetti come sovrapposizione, entanglement e qubit, che sfidano le intuizioni della computazione classica.

### 2.1.1 Qubit

Nella programmazione classica, l'unità base di informazione è il bit, che può assumere solo valori binari. Nell'ambito della computazione quantistica, l'unità base di informazione è il qubit (o qbit). Un qubit si differenzia significativamente da un bit classico poiché il suo stato è una combinazione lineare di due basi nello spazio quantistico, rappresentato da un vettore bidimensionale. Pertanto, la base computazionale del qubit è definita come segue:

$$|0\rangle = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad |1\rangle = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

Di conseguenza, un qubit generico  $|q\rangle$  può essere rappresentato come:

$$|q\rangle = \alpha|0\rangle + \beta|1\rangle$$

dove  $\alpha$  e  $\beta$  sono numeri complessi soggetti alla condizione di normalizzazione, ovvero  $|\alpha|^2 + |\beta|^2 = 1$ . Questa condizione è necessaria poiché  $|\alpha|^2$  e  $|\beta|^2$  indicano la probabilità del qubit di trovarsi nello stato 0 o 1. Il fatto che il qubit possa trovarsi in uno di questi stati con una certa probabilità è chiamato *superposition*. In altre parole, un computer quantistico composto da qubit si trova in molteplici stati contemporaneamente [3, 4].

### 2.1.2 Superposition

La superposition è una proprietà fondamentale della meccanica quantistica che consente a un qubit di esistere in una combinazione lineare di più stati di base contemporaneamente. Questo significa che, mentre un bit classico può essere in uno stato definito (0 o 1), un qubit può essere in una sovrapposizione di entrambi gli stati contemporaneamente. Questa caratteristica è fondamentale per la computazione quantistica, in quanto consente ai computer quantistici di esplorare molte soluzioni contemporaneamente, offrendo un potenziale significativo per determinate applicazioni computazionali.

### 2.1.3 Entanglement

L'entanglement o correlazione quantistica, rappresenta una connessione tra due o più particelle che condividono proprietà correlate, chiamate stati quantistici.

Il termine entanglement fu coniato da Erwin Schrödinger nel 1935 per riferirsi allo speciale legame tra le particelle nella teoria della meccanica quantistica.

Più specificamente, l'entanglement è descritto da una funzione chiamata funzione d'onda di un sistema, che descrive le proprietà delle particelle coinvolte come se fossero un unico oggetto, anche se tali particelle possono trovarsi a distanze notevoli l'una dall'altra. Questa correlazione consente ad una particella di influenzare immediatamente un'altra particella e viceversa [5].

L'entanglement è un fenomeno per cui lo stato di un qubit dipende dallo stato di un altro, indipendentemente dalla distanza che li separa. Questa proprietà dell'entanglement consente ai computer quantistici di elaborare informazioni in modo altamente interconnesso e correlato [6].

Il Quantum Computing si propone di superare limiti intrinseci posti dalla legge di Moore e dalla teoria della complessità computazionale, aprendo la strada a soluzioni efficienti per problemi altrimenti insolubili o estremamente difficili da trattare con i metodi computazionali convenzionali. Questa prospettiva innovativa ha attirato l'attenzione di ricercatori, scienziati e aziende in tutto il mondo, dando vita a una corsa globale per lo sviluppo di hardware e algoritmi quantistici.

Dunque uno degli aspetti più promettenti del quantum computing è la capacità di risolvere alcuni problemi in tempi molto più brevi rispetto ai computer classici.

## 2.2 Introduzione al Machine Learning

### Machine learning

**Il Machine learning esplora lo studio e la costruzione di algoritmi che possano imparare dai dati e sulla base di questi fare previsioni.**

Il Machine Learning è un sottoinsieme dell'intelligenza artificiale (AI) che si occupa di creare sistemi che apprendono o migliorano le performance in base ai dati che utilizzano [7]. Intelligenza artificiale è un termine generico e si riferisce a sistemi o macchine che imitano l'intelligenza umana. I termini Machine learning e AI vengono spesso utilizzati insieme e in modo interscambiabile, ma non hanno lo stesso significato.

**Storia del ML** Le prime sperimentazioni per la realizzazione di macchine intelligenti risalgono agli inizi degli anni Cinquanta del Novecento, quando alcuni matematici e statistici iniziarono a pensare di utilizzare i metodi probabilistici per realizzare macchine che potessero prendere decisioni proprio tenendo conto delle probabilità di accadimento di un evento.

Il primo grande nome legato al Machine Learning è sicuramente quello di **Alan Turing**, che ipotizzò la necessità di realizzare algoritmi specifici per realizzare macchine in grado di apprendere. In quegli stessi anni, anche gli studi sull'intelligenza artificiale, sui sistemi esperti e sulle reti neurali vedevano momenti di grande crescita alternati da periodi di abbandono, causati soprattutto dalle molte difficoltà riscontrate nelle possibilità di realizzazione dei diversi sistemi intelligenti, nella mancanza di sussidi economici e dallo scetticismo che circondava spesso chi provava a lavorarci.

A partire dagli **anni Ottanta**, una serie di interessanti risultati ha portato alla rinascita di questo settore della ricerca: una rinascita che è stata resa possibile da nuovi investimenti nel settore.

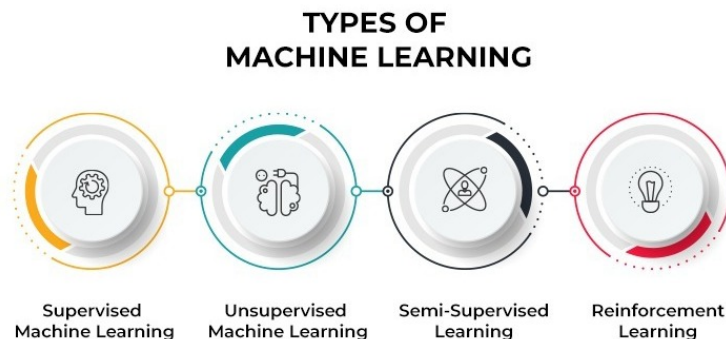


Alla fine degli **anni Novanta** l'apprendimento automatico trova nuova linfa vitale in una serie di innovative tecniche legate ad elementi statistici e probabilistici: si trattava di un importante passo che permise quello sviluppo che ha portato oggi l'apprendimento automatico ad essere un ramo della ricerca riconosciuto e altamente richiesto.

Attualmente, il Machine Learning è utilizzato ovunque. Quando interagiamo con le banche, acquistiamo online o utilizziamo i social media, vengono utilizzati gli algoritmi di Machine Learning per rendere la nostra esperienza efficiente, facile e sicura. Il Machine Learning e la tecnologia associata si stanno sviluppando rapidamente e noi abbiamo appena iniziato a scoprire le loro funzionalità.

### 2.2.1 Modelli di Machine Learning

In base all'obiettivo desiderato dall'algoritmo, gli algoritmi di apprendimento automatico sono organizzati in 4 gruppi, come mostra la Figura 2.2 [8, 9]:



**Figura 2.2:** Types of ML.

- **Supervised Machine Learning:** il compito è quello di apprendere una funzione che mappa un input in un output sulla base di coppie input-output di esempio; gli algoritmi di apprendimento supervisionato sono quelli che necessitano di assistenza esterna.
- **Unsupervised Machine Learning:** modella un insieme di input dove gli esempi etichettati non sono disponibili.

- **Semi-Supervised Machine Learning:** combina esempi etichettati e non etichettati per generare una funzione o un classificatore appropriato.
- **Reinforcement Learning:** l'algoritmo apprende una politica su come agire data un'osservazione del mondo. Ogni azione ha un impatto sull'ambiente e quest'ultimo fornisce un feedback che guida l'algoritmo di apprendimento.

## 2.3 Pipeline di Machine Learning

Una pipeline di Machine Learning (ML) è una sequenza definita di passaggi che viene utilizzata per sviluppare, distribuire e monitorare un modello di Machine learning. Le pipeline di ML sono cicliche, in quanto ogni fase viene costruita e migliorata in modo iterativo. Ogni fase del processo di apprendimento automatico costituisce un modulo distinto all'interno della pipeline complessiva, e le diverse componenti possono essere ottimizzate e automatizzate. La pipeline collega queste fasi distinte in un processo raffinato e più efficiente [10].

Il processo di sviluppo e distribuzione di un modello di Machine learning coinvolge diversi team, dai **data scientist** che addestrano il modello ai **data engineer** che distribuiscono il modello all'interno dei sistemi dell'organizzazione. Poiché il ciclo di vita del Machine learning coinvolge molteplici team e aree diverse, la pipeline funge da linguaggio comune di comprensione tra tutti i team coinvolti.

È importante sottolineare che la pipeline di Machine learning è un prodotto in sé, un progetto mappato per lo sviluppo di modelli di Machine learning che può essere automatizzato o riutilizzato.

Ogni fase della pipeline di Machine learning deve essere chiaramente definita in modo che possa essere creata e riutilizzata in nuove pipeline. Questa **riutilizzabilità** rappresenta un punto di forza, in quanto le pipeline esistenti possono essere riproposte, risparmiando tempo e risorse nello sviluppo di nuovi modelli di Machine learning. Ogni componente specifica della pipeline può essere ottimizzata per essere il più dinamica possibile.

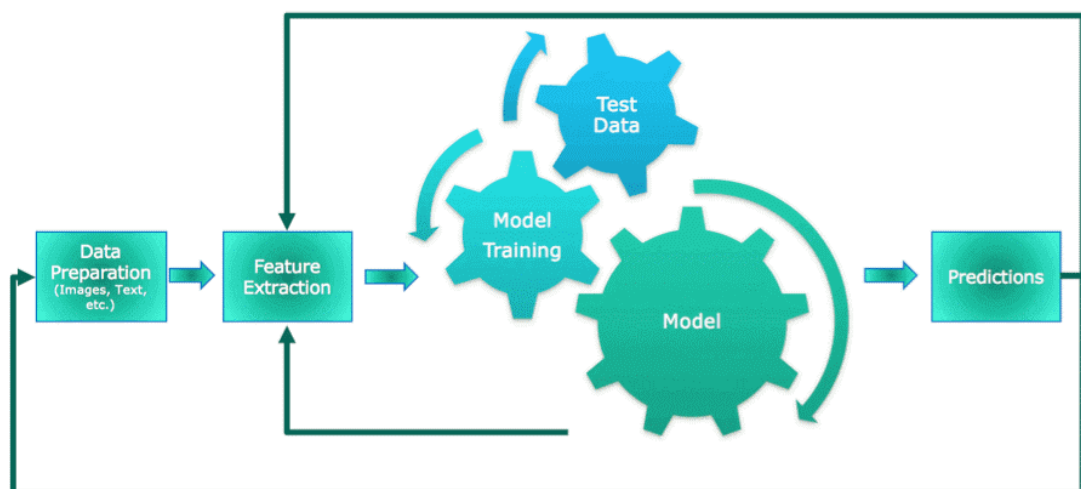
Lo scopo di una pipeline è delineare il processo del modello di Machine learning, una serie di passaggi che lo portano dallo sviluppo iniziale alla distribuzione e oltre.

I vantaggi di una pipeline di Machine learning includono:

- Mappatura di un processo complesso che include input da diverse specializzazioni, fornendo uno sguardo olistico all'intera sequenza di passaggi.
- La possibilità di concentrarsi isolatamente su fasi specifiche nella sequenza, consentendo l'ottimizzazione o l'automazione delle singole fasi.
- Il primo passo per trasformare un processo manuale di sviluppo di Machine learning in una sequenza automatizzata.
- Un prototipo per altri modelli di Machine learning, con ogni fase della sequenza che può essere perfezionata e modificata a seconda del caso d'uso.
- Soluzioni disponibili per l'orchestrazione delle pipeline, per migliorare l'efficienza e automatizzare i passaggi.
- Parti modulari facilmente scalabili e potenziabili della pipeline di Machine learning quando necessario.

Una pipeline di Machine learning è un processo sequenziale che va dalla raccolta dei dati fino alla distribuzione del modello addestrato [11].

Esistono principalmente sette fasi di costruzione di una pipeline ML, come mostra la Figura 2.3 :



**Figura 2.3:** Pipeline di Machine Learning.

**Inserimento dati** In questa fase, i dati vengono raccolti da diverse fonti, come database, file CSV o API. I dati possono essere strutturati o non strutturati e possono includere testo, immagini, audio o video. È importante assicurarsi che i dati siano di alta qualità e rappresentativi del problema che si sta cercando di risolvere.

**Data Processing** La fase di elaborazione dati, seppur impegnativa in termini di tempo, coinvolge l'acquisizione di input e la conversione di dati non organizzati in formati utilizzabili per i modelli. In questo processo, una pipeline distribuita valuta la qualità dei dati, correggendo differenze strutturali, punti dati errati o mancanti, valori anomali e altre irregolarità. La fase comprende anche il fondamentale processo di feature engineering. Una volta che i dati sono inseriti nella pipeline, inizia la progettazione delle funzionalità, e tutte le caratteristiche generate vengono memorizzate in un repository dedicato. L'output delle funzionalità viene successivamente trasferito all'archiviazione online dei dati delle funzionalità al termine di ciascuna pipeline, facilitando il recupero efficiente dei dati.

**Data Splitting** L'obiettivo principale di una pipeline di dati di Machine learning è applicare un modello accurato ai dati su cui non è stato addestrato, in base all'accuratezza della previsione delle funzionalità. Per valutare il funzionamento del modello rispetto ai nuovi set di dati, a questo punto è necessario dividere i dati etichettati esistenti in sottoinsiemi di dati di training, test e convalida.

**Model Training** In questa fase, il data scientist implementa diversi algoritmi di Machine learning, applicando tali algoritmi ai dati precedentemente preparati con l'obiettivo di addestrare molteplici modelli. Inoltre, sottopone gli algoritmi implementati a un processo di ottimizzazione degli iperparametri, con l'intento di derivare il modello di Machine learning che dimostri le prestazioni ottimali. L'output di questa fase è rappresentato da un modello addestrato, pronto per essere utilizzato per previsioni e analisi nei contesti pertinenti.

**Model Evaluation** Questa fase valuta le prestazioni predittive dei modelli archiviati utilizzando sottoinsiemi di dati di test e convalida finché un modello non risolve il

problema aziendale in modo efficiente. La fase di valutazione del modello utilizza diversi criteri per confrontare le previsioni sul set di dati di valutazione con i valori effettivi. L'output di questo passaggio è un insieme di metriche per valutare la qualità del modello.

**Model Deployment** Dopo il completamento della fase di valutazione del modello, la pipeline procede con la selezione del modello ottimale e ne avvia la distribuzione. Al fine di garantire una transizione graduale tra modelli precedenti e quelli appena introdotti, la pipeline è in grado di implementare diversi modelli di Machine learning simultaneamente. Durante questo processo di distribuzione, i servizi all'interno della pipeline mantengono la loro operatività, rispondendo a nuove richieste di previsione. Ciò consente una transizione fluida e continua tra i modelli, garantendo al contempo la continuità del servizio durante l'implementazione di nuovi approcci predittivi.

**Monitoraggio delle prestazioni del modello** La fase conclusiva di una pipeline nel contesto del Machine learning consiste nel monitoraggio continuo delle prestazioni del modello e nell'assegnazione di punteggi ad tali prestazioni. Questa fase implica la regolare e sistematica osservazione del comportamento del modello al fine di apportarvi miglioramenti graduati nel tempo. I modelli vengono impiegati per assegnare punteggi basati sui valori delle caratteristiche importati dalle fasi precedenti del processo. Alla ricezione di una nuova previsione, il servizio di monitoraggio delle prestazioni è notificato, avvia l'analisi delle prestazioni, registra i risultati ottenuti e genera eventuali avvisi necessari. Tale processo comporta un confronto tra il punteggio predetto e i risultati osservati generati durante la valutazione della pipeline di dati. Diversi metodi di monitoraggio possono essere adottati, tra cui l'utilizzo diffuso dell'analisi dei log attraverso strumenti come Kibana, Grafana, Splunk, e simili.

## 2.4 QML: Un'Integrazione Rivoluzionaria tra Computazione Quantistica e Apprendimento Automatico

Il Quantum Machine Learning (QML) rappresenta un'intersezione affascinante tra due discipline di studio fondamentali: la computazione quantistica e il Machine Learning. Negli ultimi anni, con l'avanzamento della tecnologia dei computer quantistici e i progressi nella manipolazione dei qubit, si è aperta la possibilità di sfruttare le caratteristiche uniche della meccanica quantistica per migliorare l'efficienza e l'accuratezza degli algoritmi di apprendimento automatico [12, 13].

La combinazione di questi due campi, offre nuove prospettive ed affronta sfide che richiedono una comprensione approfondita delle differenze nella pipeline del QML rispetto al Machine Learning tradizionale. Nel QML, invece di utilizzare i classici bit come unità di elaborazione delle informazioni, si sfruttano i **qubit**, che a differenza dei bit classici, possono esistere in uno stato di sovrapposizione simultaneamente rappresentando 0 e 1 con una certa probabilità. Questa caratteristica permette ai qubit di eseguire calcoli paralleli e di sfruttare le proprietà quantistiche per risolvere problemi in modo più efficiente rispetto ai sistemi classici.

Questo apre la strada a nuovi algoritmi e approcci che sfruttano il concetto di sovrapposizione e l'entanglement<sup>1</sup> dei qubit per effettuare calcoli complessi in modo molto più rapido rispetto ai computer classici. Alcuni algoritmi quantistici, come l'algoritmo di Grover<sup>2</sup> e l'algoritmo di ricerca quantistica, hanno dimostrato un'accelerazione significativa rispetto alle controparti classiche nei compiti di ricerca e di ottimizzazione. Tuttavia, il Quantum Machine Learning è un contesto caratterizzato da un'elevata dinamicità e da numerose sfide intrinseche.

Le sfide nel QML possono derivare da diverse fonti, come:

- L'elaborazione e la manipolazione dei dati quantistici,
- La progettazione di algoritmi adatti ai computer quantistici,
- La gestione dell'errore quantistico,

---

<sup>1</sup>Correlazione quantistica che può esistere tra due o più qubit.


<sup>2</sup>Algoritmo quantistico progettato per accelerare la ricerca non strutturata.

- La necessità di garantire la stabilità e la coerenza dei qubit durante l'esecuzione dei calcoli.

La coerenza e la stabilità dei qubit sono ancora problematiche, con fenomeni come la decoerenza che possono influire sui risultati. Inoltre, l'accesso ai computer quantistici è ancora limitato e richiede competenze specializzate per essere utilizzato in modo efficace.


### Cenni Storici [14]

- Anni '90:
  - Nel 1992, David Deutsch e Richard Jozsa hanno proposto l'**algoritmo di Deutsch-Jozsa** un algoritmo quantistico deterministico. Tale algoritmo è stato il primo a mostrare una separazione tra la difficoltà quantistica e classica di un problema. Questo algoritmo ha evidenziato l'importanza di consentire alle ampiezze quantistiche di assumere valori sia positivi che negativi, al contrario delle probabilità classiche che sono sempre non negative [15].
  - Nel 1994, il fisico americano Peter Shor ha presentato l'**algoritmo di fattorizzazione di Shor** (Figura 2.4), che ha dimostrato il potenziale delle macchine quantistiche nel risolvere problemi complessi come la fattorizzazione di numeri primi in modo efficiente. Nello specifico, l'algoritmo classico si dice avere una complessità subesponenziale nel parametro  $n$  mentre quello quantistico complessità polinomiale in  $n$ . Questo ha attirato l'attenzione sulla potenziale applicazione della teoria quantistica nel campo del Machine learning [16].



**Figura 2.4:** Algoritmo di Shor.

- Nel 1996, Lov Grover ha presentato l'**algoritmo di ricerca quantistica di Grover** (Figura 2.5). Questo algoritmo ha fornito una dimostrazione pratica dell'utilità dei computer quantistici nell'elaborazione dei dati, mostrando come un computer quantistico possa effettuare la ricerca di un elemento all'interno di un database non strutturato in un tempo  $O(\sqrt{N})$ , dove  $N$  è la dimensione del database, a differenza dell'algoritmo classico che richiede un tempo lineare per la ricerca. L'algoritmo di Grover ha suscitato un grande interesse nella comunità scientifica e ha dimostrato il potenziale dei computer quantistici nel migliorare il riconoscimento di pattern nei dati.



**Figura 2.5:** Algoritmo di ricerca di Grover.

- Anni 2000:
  - Negli anni successivi, sono stati fatti progressi significativi in tale ambito. Sono stati proposti algoritmi specifici, come l'algoritmo di apprendimento di supporto vettoriale quantistico (**Q-SVM**) e l'algoritmo di apprendimento delle componenti principali quantistiche (**Q-PCA**). Questi algoritmi hanno combinato i principi del Machine learning classico con la teoria quantistica per migliorare l'elaborazione dei dati e l'apprendimento delle macchine quantistiche.
- Anni 2010:
  - Con l'aumento dell'accessibilità agli hardware quantistici, gli studi nel campo del QML hanno registrato una crescita significativa. Sono state



condotte ricerche per comprendere meglio il potenziale del QML in settori specifici come la chimica quantistica, l'ottimizzazione e la visione artificiale.

- Nel 2017, è stato introdotto il concetto di **Quantum Neural Networks** (QNN), che combina principi di reti neurali artificiali con l'elaborazione quantistica. Le QNN offrono un approccio promettente per il QML, consentendo di sfruttare le proprietà uniche della computazione quantistica per migliorare le capacità di apprendimento delle reti neurali.
- Anni recenti:
    - Negli ultimi anni, il QML ha continuato a suscitare interesse e ricerca attiva. Sono stati fatti progressi significativi nell'algoritmo di apprendimento quantistico, nell'implementazione di reti neurali quantistiche e nell'analisi delle prestazioni dei modelli quantistici.
    - Parallelamente, sono state condotte sperimentazioni e simulazioni per valutare le prestazioni dei modelli quantistici rispetto a quelli classici in diverse applicazioni: la chimica computazionale, l'ottimizzazione e il riconoscimento di pattern.

Da notare che il campo del QML è ancora in fase di sviluppo e molte delle sue applicazioni pratiche devono essere pienamente realizzate. Tuttavia, gli sviluppi e le ricerche in corso indicano che il QML potrebbe svolgere un ruolo significativo nell'evoluzione del Machine learning e nell'affrontare problemi complessi in modo più efficiente e innovativo.

In questo capitolo, è stata fornita una panoramica dettagliata sul background e lo stato dell'arte del Quantum Machine Learning rispetto al Machine Learning tradizionale. Nel capitolo successivo, verrà condotta la Systematic Literature Review in merito alla pipeline del QML e alle sue differenze chiave, identificando anche le lacune e le direzioni future.

---

### Attività Di Ricerca: Metodologia e Strumenti

---

In questo capitolo, si procederà a illustrare l'attività di ricerca svolta, gli strumenti impiegati e le diverse fasi di analisi condotte. In particolare, verranno delineate le strategie di ricerca utilizzate per raccogliere e documentare i fattori chiave che caratterizzano le differenze tra il Quantum Machine Learning e il Machine Learning tradizionale. L'analisi della letteratura presentata avrà come scopo principale quello di fornire linee guida preziose per coloro che intendono immergersi in queste discipline.

© **Our Goal.** Esplorare le Differenze nella Pipeline tra Quantum Machine Learning (QML) e Machine Learning Tradizionale (ML) e Fornire Linee Guida per Aspiranti Esploratori.

#### 3.1 Revisione sistematica della letteratura

Una revisione sistematica, o Systematic Review, è uno strumento secondario di ricerca scientifica il cui obiettivo è quello di riassumere dati provenienti da strumenti di ricerca primari.

Ad esempio, con una rassegna esaustiva della letteratura scientifica relativa a un dato argomento e con particolare attenzione alle fonti, che devono essere altamente referenziate, per individuare, evidenziare e valutare, in ricerca di alta qualità, tutte le prove pertinenti a una specifica questione scientifica.

La Systematic Review usa metodi chiari e pianificati, nonché step specifici, per identificare, selezionare, valutare e sintetizzare studi simili [17, 18].

**Tabella 3.1:** Step Systematic Literature Review.

#	Step
1	Descrizione del problema di ricerca
2	Descrizione del protocollo di ricerca bibliografica
3	Definizione delle strighe di ricerca
4	Definizione dei criteri di inclusione\esclusione
5	Valutazione della qualità
6	Estrazione dei dati

*Note:* Tra lo step 3 e 5, si applica la tecnica di campionamento *Snowballing*, sia *backward* che *forward*.

## 3.2 Descrizione del problema di ricerca

Negli ultimi anni, l'interesse per il Machine Learning è cresciuto in modo esponenziale, grazie alla sua capacità di analizzare grandi quantità di dati e di trarre conclusioni utili per le attività umane. Tuttavia, il recente sviluppo della tecnologia quantistica ha aperto la strada a nuovi paradigmi di calcolo e di elaborazione dei dati, aprendo la possibilità di applicare il Machine Learning su sistemi quantistici. La combinazione di questi due campi ha dato vita al Quantum Machine Learning, una nuova disciplina che sfrutta le proprietà della meccanica quantistica per elaborare e analizzare i dati. In questo contesto, sorge spontanea la domanda su quali siano le differenze nella pipeline del Quantum Machine Learning rispetto a quella del

Machine Learning tradizionale, al fine di comprendere meglio le potenzialità e le limitazioni di questa nuova disciplina e le sue possibili applicazioni pratiche.

**Q RQ.** *Quali sono le principali fasi di una pipeline di QML e come si differenziano dalle pipeline di ML tradizionale?*

Questa domanda di ricerca è di grande rilevanza sia dal punto di vista teorico che applicativo. Da un lato, essa contribuisce a sviluppare una comprensione più approfondita dei fondamenti teorici del Quantum Machine Learning e delle potenzialità offerte dalla meccanica quantistica nell'ambito dell'elaborazione dei dati. Dall'altro lato, essa può fornire indicazioni utili per la progettazione di nuovi algoritmi di Machine Learning basati su sistemi quantistici e per lo sviluppo di applicazioni avanzate in diversi campi, come ad esempio l'analisi dei dati finanziari, la modellizzazione del clima e la diagnostica medica.

Tuttavia, nonostante l'interesse crescente per il Quantum Machine Learning, le differenze tra la pipeline del QML e quella del ML tradizionale non sono ancora ben comprese e definite. Pertanto, una revisione sistematica della letteratura sul tema, può fornire una panoramica completa e aggiornata delle conoscenze attuali e rappresentare un importante punto di partenza per la definizione di nuove linee di ricerca e per lo sviluppo di applicazioni innovative.

Alla base del problema, per strutturare la domanda di ricerca in modo chiaro e preciso, è stato utilizzato il modello **P.I.C.O.C.** :

(Population, Intervention, Comparison, Outcome, Context)

- **Popolazione:** studi sulla pipeline del Quantum Machine Learning (QML) e del Machine Learning (ML) tradizionale.
- **Intervento:** realizzazione di pipeline di Machine Learning.
- **Confronto:** valutazione delle differenze tra la pipeline del QML e quella del ML tradizionale.
- **Esito:** identificare i vantaggi e gli svantaggi della pipeline del QML rispetto a quella del ML tradizionale.

- **Contesto:** studi pubblicati fino a Novembre 2023.
- **Metodi:** una SLR sistematica della letteratura scientifica sui principali database, selezionando gli studi pertinenti e valutando la qualità e l'affidabilità degli stessi.

### 3.3 Protocollo di ricerca bibliografica

Per la revisione sistematica, è necessario definire un protocollo di ricerca, le fonti di ricerca e le strategie di ricerca. I criteri di inclusione ed esclusione devono essere definiti in modo preciso e trasparente, così da garantire la riproducibilità del processo di selezione degli studi. Ad esempio, possono essere inclusi studi che presentano una comparazione tra la pipeline del QML e quella del ML tradizionale, che utilizzano un approccio metodologico rigoroso e che sono stati pubblicati in riviste scientifiche con peer-review. D'altra parte, possono essere esclusi studi che non rispondono a questi criteri, come ad esempio articoli di divulgazione, relazioni tecniche o studi con un basso livello di qualità metodologica.

In questo studio, per sfruttare al meglio le risorse disponibili, si è deciso di utilizzare 3 principali database bibliografici:

- **ACM Digital Library:** una raccolta di pubblicazioni dell'Association for Computing Machinery (ACM), che include articoli scientifici, atti di conferenze, libri e relazioni tecniche su informatica e tecnologia.
- **IEEE Xplore Digital Library:** una delle maggiori fonti di informazioni sugli ultimi sviluppi in ingegneria, tecnologia e informatica, che include una vasta gamma di articoli scientifici e documenti tecnici.
- **Scopus:** un database bibliografico che copre una vasta gamma di discipline scientifiche, tra cui l'informatica, e fornisce accesso a oltre 70 milioni di record di articoli scientifici, libri e atti di conferenze.

La decisione di limitare la selezione a questi specifici database è stata guidata dalla considerazione che essi soddisfacevano in modo adeguato le esigenze del contesto senza necessità di includerne ulteriori. Questi database fornivano una copertura

completa e rilevante per gli scopi dello studio, evitando così l'inclusione di risorse superflue che potrebbero aver condotto a duplicazioni e complicazioni non necessarie. In breve, la scelta di concentrarsi su questi database è stata motivata dalla loro idoneità e completezza nel contesto specifico, garantendo al contempo un'efficienza nella gestione delle informazioni senza introdurre ulteriori ridondanze.

### 3.4 Definizione delle strighe di ricerca

La definizione della stringa di ricerca rappresenta una fase cruciale per ottenere risultati ottimali in un processo di recupero delle informazioni basato su linguaggio naturale (SLR).

Nella nostra indagine, la formulazione di questa stringa è stata particolarmente complessa, poiché la ricerca diretta di "Differenze nella pipeline del QML rispetto a quella del ML tradizionale" si è rivelata estremamente limitante e, in alcuni casi, priva di risultati significativi. Pertanto, abbiamo adottato un approccio analitico più dettagliato, suddividendo la generica pipeline di Quantum Machine Learning (QML) in diverse fasi. Abbiamo iniziato a combinare diverse parole chiave al fine di ottenere risultati rilevanti per il nostro specifico caso di studio.

Le parole chiave sono state selezionate e combinate con attenzione per rispondere alla domanda di ricerca e per includere possibili articoli scientifici utili.

I concetti chiave che ci hanno ispirato includono:

- Quantum Machine Learning algorithms vs classical algorithms
- Quantum data encoding techniques in Machine Learning
- Comparative analysis of quantum and classical feature selection
- Differences in data preprocessing for quantum and classical Machine Learning
- "Hybrid quantum-classical models in Machine Learning pipelines"

Questi concetti sono stati scelti con attenzione perché, dopo un'analisi approfondita, è emerso che, sebbene i risultati fossero ampi e non sempre direttamente

correlati alla nostra domanda di ricerca, essi includevano elementi di pipeline e concetti rilevanti per il nostro studio.

Le parole chiave selezionate sono state le seguenti: *Quantum Machine Learning*, *Quantum Computing*, *Machine Learning*, *artificial intelligence*, *pipeline*, *workflow* e *process*.

Queste prime quattro parole chiave sono mirate a individuare articoli rilevanti sull'argomento generale, mentre le altre sono state scelte specificamente per concentrarsi sulle differenze operative e metodologiche tra le due tecniche.

La combinazione di queste parole chiave può essere effettuata attraverso l'uso di filtri, come operatori logici (AND, OR, ecc.), che permettono di raffinare i risultati ottenuti. Questi operatori sono strumenti utili per affinare la ricerca, consentendo di focalizzarsi su articoli che trattano contemporaneamente più concetti o di ampliare la ricerca includendo articoli che coprono almeno uno dei termini chiave. L'applicazione oculata di tali filtri contribuirà a ottimizzare la precisione e la pertinenza dei risultati.

Dopo una serie di prove e cambiamenti della query, il risultato è stato il seguente:

**Query**

**("Quantum" OR "Quantum Computing") AND ("Machine Learning" OR "artificial intelligence") AND ("pipeline" OR "workflow" OR "process")**

### 3.5 Definizione dei criteri di inclusione\esclusione

I criteri di esclusione e inclusione consentono la selezione di risorse che affrontano le domande di ricerca di una revisione sistematica della letteratura. Nel contesto di questo lavoro di tesi, sono stati identificati e applicati i seguenti criteri.

Criteri di selezione dello studio	
Criteri di esclusione	Criterio di inclusione
<ul style="list-style-type: none"> <li>• Articoli non sottoposti a peer review.</li> <li>• Articoli non in inglese.</li> <li>• Articoli di convegni estesi su riviste.</li> <li>• Articoli duplicati.</li> <li>• Articoli il cui testo non era disponibile</li> </ul>	<ul style="list-style-type: none"> <li>• Articoli sottoposti a peer review pubblicati negli ultimi 5 anni.</li> <li>• Articoli che presentano una comparazione diretta tra il Quantum Machine Learning e il Machine Learning tradizionale.</li> <li>• Articoli che forniscono esempi specifici di algoritmi e tecniche utilizzate nella pipeline del Quantum Machine Learning.</li> <li>• Articoli che discutono le limitazioni e le sfide della pipeline del Quantum Machine Learning.</li> </ul>



## 3.6 Valutazione della qualità

Prima di procedere con l'estrazione dei dati, è essenziale condurre una fase di valutazione della qualità al fine di garantire l'integrità e la completezza, riducendo al minimo il rischio di bias e risultati erranei. A tal fine, è stata sviluppata una checklist con le seguenti domande:

### 1. Chiarezza della Motivazione:

La motivazione dell'articolo, con particolare attenzione alle differenze nelle pipeline tra Quantum Machine Learning e Machine Learning Tradizionale, è presentata in modo chiaro ed esplicito?

### 2. Chiarezza del Risultato Principale:

Il risultato principale del documento, concentrandosi sulle differenze nelle pipeline tra Quantum Machine Learning e Machine Learning Tradizionale, è riportato in modo chiaro ed esplicito?

Per ogni domanda, viene assegnato un punteggio secondo la seguente scala:

- 1 punto se la risposta è **Sì, esplicitamente**.
- 0,5 punti se la risposta è **Sì, ma non riportata esplicitamente**.
- 0 punti se la risposta è **Non riportata**.

La valutazione complessiva della qualità è stata ottenuta mediante la somma dei punteggi attribuiti alle risposte alle due domande. Gli articoli inclusi nella revisione sono stati limitati a quelli che hanno ottenuto un punteggio di qualità pari o superiore a 1.

## 3.7 Estrazione dei dati

Nell'ultimo step della SLR, è stata attentamente condotta la fase di estrazione dei dati per raccogliere informazioni cruciali necessarie a rispondere alle domande di ricerca. Le informazioni estratte includono:

Informazioni	Dettagli
<b>Titolo</b>	Il titolo di ciascun articolo o studio analizzato fornisce un'indicazione preliminare del suo contenuto e dell'approccio specifico verso il Quantum Machine Learning.
<b>Autore</b>	L'identificazione degli autori è essenziale per attribuire credibilità e autorità agli studi considerati. Conoscere gli autori fornisce anche un contesto sulla loro competenza nel campo.
<b>Anno di Pubblicazione</b>	La data di pubblicazione è un elemento temporale importante per comprendere la cronologia delle ricerche nel campo del Quantum Machine Learning e per valutare eventuali progressi nel tempo.
<b>Riferimento Bibliografico</b>	Raccogliere i riferimenti bibliografici consente di esplorare ulteriormente le fonti primarie e di valutare la coerenza delle informazioni presentate nei vari studi.
<b>Tipo di Studio Condotta</b>	Identificare il tipo di studio (sperimentale, teorico, revisione della letteratura, etc.) fornisce contesto sulla metodologia utilizzata e sulla natura delle evidenze presentate.
<b>Risultati Individuati</b>	Estratti i risultati specifici relativi alla pipeline di Quantum Machine Learning e Machine Learning tradizionale. Questi risultati possono includere differenze nell'algoritmo, nell'approccio computazionale, o negli ambiti di applicazione.

Queste informazioni estratte consentono una risposta completa alle domande di ricerca e forniscono una panoramica esaustiva delle differenze nella pipeline tra

QML e ML tradizionale, facilitando la comprensione delle sfide e delle opportunità presenti in entrambi i campi.

## CAPITOLO 4

---

### Risultati

---

In questo capitolo, esploreremo l'attuazione del processo di revisione sistematica della letteratura (SLR) insieme ai risultati conseguiti. Approfondiremo le scoperte emerse durante l'analisi accurata delle fonti esistenti, presentando in modo chiaro i risultati chiave identificati.

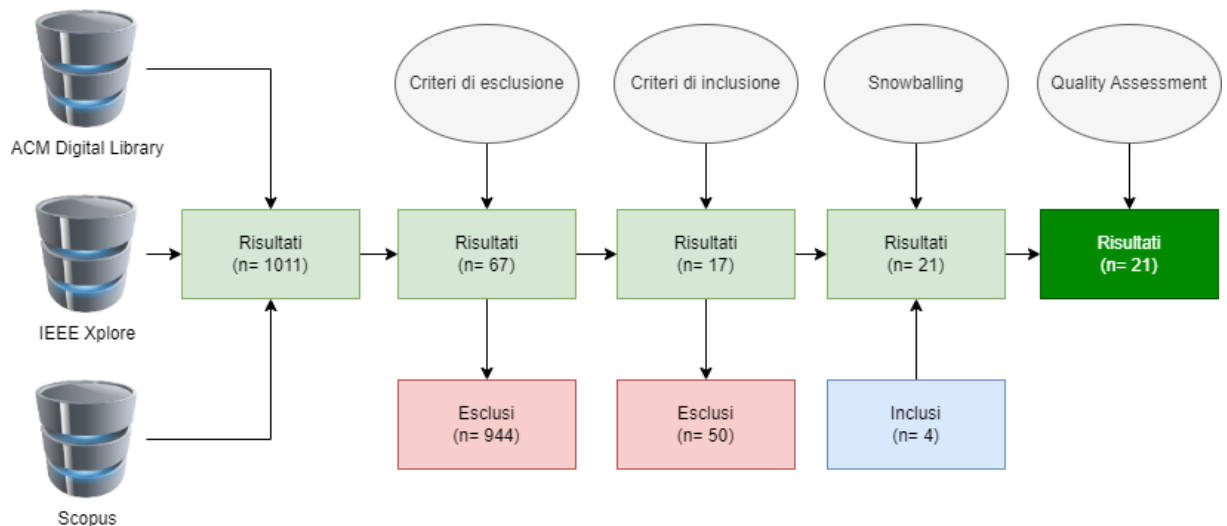
#### 4.1 Esecuzione del processo di ricerca

Una volta definito gli step della SLR, si è proceduto con la sua esecuzione, vedere la Figura 4.1 :

- (I) Il primo passo è stato quello di eseguire la query di ricerca sui 3 database selezionati. Tale query ha prodotto un totale di **1.011** risultati, distribuiti su ACM Digital Library, IEEE Xplore e Scopus. Il completamento di tale passo è stato fatto scaricando e archiviando tutti i documenti in un ambiente locale per un'indagine più rapida.
- (II) Nel secondo passo sono stati applicati i criteri di esclusione. Sono stati scansionati tutti i paper e sono stati applicati i filtri. Per prima cosa sono stati eliminati tutti i paper duplicati, si è considerato il titolo, il tipo, l'abstract e le parole chia-

ve per decidere se scartarli. Complessivamente sono stati scartati **944** documenti e **67** sono passati alla fase successiva.

- (III) Nel terzo passo sono stati applicati i criteri di inclusione. I 67 documenti sono stati scansionati in modo dettagliato senza soffermarci solo su titolo, tipo e abstract, ma sull'intero articolo. Tale passo ha permesso di scartare **50** articoli, così da condurre alla fase successiva i **17** documenti.
- (IV) Nel quarto passo con i 17 documenti mediante **Research Rabbit** è stato svolto lo snowballing sia in avanti che all'indietro, sono state analizzate le citazioni e le references dei documenti. Tale passo ha aggiunto 4 documenti.
- (V) Nel quinto passo è stata effettuata la valutazione della qualità (Quality Assessment). Questo passo è stato particolarmente oneroso in quanto sono stati valutati i documenti in base alla chiarezza e alla disponibilità di informazioni sufficienti a rispondere alle domande di ricerca.
- (VI) Infine, si è proceduto con l'estrazione dei dati, che è risultata abbastanza immediata dopo l'applicazione dei criteri e la valutazione della qualità.



**Figura 4.1:** Rappresentazione del processo di selezione degli studi.

## 4.2 Analisi dei risultati

### Timeline Tecnologica

La Figura 4.2 riporta i 21 articoli selezionati mediante il processo di ricerca e li pone in relazione con il loro anno di pubblicazione. Tale rappresentazione visiva fornisce una chiara motivazione sulla scelta del criterio di inclusione, che si concentra sugli articoli sottoposti a peer review e pubblicati negli ultimi 5 anni. Questa selezione temporale è stata motivata dalla rapida crescita del Quantum Machine Learning (QML), evidenziata dalla traiettoria ascendente del grafico.

L'andamento dinamico del QML sottolinea la necessità di considerare dati recenti. Questo approccio si rivela cruciale per ottenere una comprensione completa delle potenzialità e delle sfide intrinseche al QML, data la velocità con cui si verificano gli sviluppi in questo settore.

Come si può ben notare dalla figura, per ben due anni non sono stati pubblicati articoli rilevanti, dal 2018 al 2019, ma già dal 2020 la situazione è cambiata. L'interesse è man mano aumentato e pertanto ci si aspetta un notevole incremento nei prossimi anni. È fondamentale specificare che questa analisi è stata condotta nel mese di ottobre e, di conseguenza, i dati relativi all'anno 2023 potrebbero essere incompleti.




**Figura 4.2:** Numero di articoli pubblicati nel corso degli anni.

L'analisi della Figura 4.3 mette in luce in modo significativo che, attualmente, le conferenze (76%) rappresentano la maggioranza delle venue di interesse rispetto ai journal (24%).

Questa situazione è attribuibile al fatto che l'area di studio è ancora in fase di esplorazione, rendendo spesso i risultati non sufficientemente maturi per una pubblicazione su riviste scientifiche.

Tuttavia, al fine di aumentare la visibilità dei risultati ottenuti, si preferisce presentarli in conferenze, offrendo l'opportunità di condividere le scoperte con altri ricercatori interessati e di raccogliere feedback e spunti utili per futuri sviluppi.

Pertanto, tale tendenza potrebbe sottolineare l'importanza di considerare attentamente la partecipazione a conferenze nell'ambito delle attività accademiche.



**Figura 4.3:** Percentuale di conference e journal degli articoli selezionati.

## 4.3 La pipeline nel Machine Learning Quantistico

L'indagine condotta durante il processo di ricerca e l'analisi approfondita dei documenti selezionati hanno prodotto risultati significativi che hanno contribuito in modo sostanziale alla delineazione della pipeline nel contesto del Machine Learning Quantistico, consentendoci di rispondere alla prima parte della nostra domanda di ricerca.

🔗 **Answer to RQ.** Quali sono le principali fasi di una pipeline di QML ...

A partire dagli articoli derivanti dalla revisione della letteratura condotta, è stato applicato **open coding** al fine di estrarre le principali fasi di una pipeline di QML. Questo approccio consente una categorizzazione accurata e dettagliata delle informazioni rilevanti, contribuendo così in modo significativo alla solidità e alla completezza dei risultati ottenuti.

Le fasi identificate, complete di una descrizione dettagliata, sono riportati di seguito:

**Preparazione dei dati nel QML** La prima fase della pipeline è l'acquisizione e la preparazione dei dati. In questa fase, vengono raccolti i dati necessari per l'addestramento dell'algoritmo quantistico. Questi dati possono provenire da diverse fonti, come sensori, database o registri storici. Una volta acquisiti, i dati vengono preparati per l'addestramento, che può includere operazioni come la normalizzazione dei dati, la rimozione dei valori anomali o la codifica delle caratteristiche.

**Addestramento dei modelli nel QML** La seconda fase è l'addestramento dell'algoritmo quantistico. In questa fase, i dati preparati vengono utilizzati per addestrare l'algoritmo, che è progettato per apprendere dai dati e creare un modello predittivo. Durante l'addestramento, l'algoritmo quantistico sfrutta le proprietà quantistiche, come la sovrapposizione e l'entanglement, per elaborare i dati in modo più efficiente rispetto agli algoritmi classici. L'obiettivo dell'addestramento è quello di ottimizzare



le prestazioni del modello predittivo, in modo da poter fare previsioni accurate su nuovi dati.


**Valutazione e implementazione del modello quantistico** Infine, la terza fase della pipeline è la valutazione e l'implementazione del modello. Una volta addestrato, il modello viene valutato utilizzando dati di test indipendenti per verificare le sue prestazioni. Se il modello supera i criteri di valutazione, può essere implementato e utilizzato per fare previsioni su nuovi dati in tempo reale. Durante l'implementazione, possono essere necessari ulteriori passaggi, come l'ottimizzazione del modello per la specifica piattaforma quantistica utilizzata o l'integrazione con altre tecnologie o sistemi. L'obiettivo finale della pipeline nel Machine Learning Quantistico è quello di creare modelli predittivi accurati e efficienti che possano essere utilizzati in una varietà di settori, come la finanza, la salute o l'ottimizzazione dei processi.

Dopo aver completato il processo di ricerca, il quale ha consentito di rispondere alla domanda posta, è risultato opportuno organizzare i risultati in maniera più efficace, seguendo la convenzione di suddividerli nelle diverse fasi della pipeline. Tale decisione è stata presa considerando che i documenti analizzati non offrivano una panoramica completa riguardo a tutte le differenze della pipeline, ma presentavano dettagli specifici relativi a parti ben definite.

La Figura 4.4 illustra il numero di articoli analizzati per ciascuna fase. Analizzandola, possiamo ben osservare che la somma degli articoli per ogni fase eccede il numero totale degli articoli selezionati. Questo avviene poiché diversi articoli trattano più di una fase, contribuendo a un'analisi più completa e articolata del processo in questione. Tale osservazione sottolinea l'importanza di considerare la complessità e l'interconnessione delle fasi coinvolte nel contesto della ricerca.

La fase di "addestramento dei modelli" durante la Revisione della Letteratura è stata la fase con il maggior volume di informazioni disponibili; pertanto, ha registrato un riscontro più ampio rispetto alle altre fasi.

Inoltre, pur non essendo elevato, il numero di articoli si è rivelato sufficiente per condurre confronti significativi.



**Figura 4.4:** Numero di articoli analizzati per ogni fase.

Di seguito verrà riportata la Tabella 4.1 delle fonti analizzate per ogni fase della pipeline.

**Tabella 4.1:** Elenco delle fonti per ogni fase

Fase	Fonti
Preparazione dei dati nel QML	S01, S02, S03, S04, S05, S06, S07
Addestramento dei modelli nel QML	S04, S06, S08, S09, S10, S11, S12, S13, S14
Valutazione delle prestazioni nel QML	S10, S15, S16, S17, S18
Ottimizzazione dei parametri nel QML	S05, S18, S19, S20, S21

Inoltre, verranno riportati i grafici 4.5, 4.6, 4.7, 4.8 i quali forniscono una panoramica chiara dell'andamento temporale.

Rappresentano il numero di articoli pubblicati per ogni anno suddivisi per fase.

### 1. Preparazione dei dati:

La Figura 4.5 mette in evidenza chiaramente che nel corso del 2021, la fase di preparazione dei dati ha registrato un notevole interesse, superando gli altri anni in termini di rilevanza. La motivazione principale che ha caratterizzato l'anno 2021 è stata la discussione sulla provenienza di dati da diverse fonti, come sensori e database.

Questo argomento è stato oggetto di approfondite discussioni in numerose conferenze, sottolineando la significativa importanza e l'attenzione dedicata a tale tematica.




**Figura 4.5:** Numero di articoli pubblicati nel corso degli anni per la fase di preparazione dei dati.

### 2. Addestramento dei modelli:

La Figura 4.6 ci mostra come nel corso degli anni l'interesse per la fase di addestramento dei modelli nel QML sia cresciuto.


Tale crescita potrebbe essere attribuita alla crescente disponibilità di risorse e opportunità di formazione nel campo del QML, le quali potrebbero aver stimolato una maggiore partecipazione e investimenti da parte dei ricercatori e degli esperti del settore.



**Figura 4.6:** Numero di articoli pubblicati nel corso degli anni per la fase di addestramento dei modelli.

### 3. Valutazione delle prestazioni:


La Figura 4.7 evidenzia chiaramente che nel corso del 2022, si è registrata una notevole attenzione per la fase di valutazione delle prestazioni, superando gli altri anni in termini di rilevanza. Tale aumento di interesse potrebbe essere attribuito alle sfide intrinseche degli **algoritmi quantistici** e all'introduzione di **nuove metriche** di valutazione, le quali hanno stimolato una maggiore attenzione nei confronti di questa fase.



**Figura 4.7:** Numero di articoli pubblicati nel corso degli anni per la fase di valutazione delle prestazioni.

#### 4. Ottimizzazione dei parametri:

La Figura 4.8 indica chiaramente un aumento dell'interesse nei confronti della fase di ottimizzazione dei parametri, suggerendo una tendenza in crescita. Anche in questo caso, il crescente accesso a risorse di calcolo quantistiche potrebbe aver reso più praticabile l'ottimizzazione dei parametri, aprendo nuove opportunità per sperimentare e migliorare le prestazioni dei modelli quantistici.




**Figura 4.8:** Numero di articoli pubblicati nel corso degli anni per la fase di ottimizzazione dei parametri.

## 4.4 Differenze nella pipeline del QML rispetto al Machine Learning tradizionale

Questa sezione riporta e discute alcune considerazioni personali, volte ad evidenziare le differenze tra le pipeline di QML e quelle di ML tradizionale.

🔗 **Answer to RQ.** ... come si differenziano dalle pipeline di ML tradizionale?

Saranno analizzati i principali aspetti quali: la **preparazione dei dati**, la fase di **addestramento dei modelli**, la **valutazione delle prestazioni** e l'**ottimizzazione dei parametri**. Saranno evidenziate le peculiarità introdotte dalla computazione quantistica e come queste influenzino l'intero processo di apprendimento automatico. L'obiettivo sarà fornire una visione dettagliata di come il QML si differenzi dal ML tradizionale, aprendo nuove prospettive e sfide entusiasmanti per lo sviluppo di modelli e algoritmi avanzati.



**Figura 4.9:** QML vs ML.

### 4.4.1 Preparazione dei dati nel QML

Le osservazioni e i risultati successivi sono basati sui documenti indicati nella tabella 4.1.

La preparazione dei dati nel contesto del QML richiede una considerazione speciale per la codifica dei dati quantistici e la rappresentazione delle feature.

La prima differenza che si evince dal confronto con l'approccio tradizionale è che il QML sfrutta i **qubit** per memorizzare e manipolare le informazioni.

Pertanto, è necessario considerare le tecniche di codifica dei dati quantistici quali:

- **L'encoding di base** (o "basis encoding") prevede la trasformazione dei dati classici in stringhe binarie e la mappatura di ciascuna stringa binaria allo stato di base di un insieme di qubit di un sistema composito.
- **L'encoding di ampiezza** (o "amplitude encoding") prevede la rappresentazione dei dati classici come una sovrapposizione di stati di base di un sistema quantistico.
- **L'encoding di campioni** (o "qsample encoding") prevede la rappresentazione dei dati classici come una sovrapposizione di stati di base di un sistema quantistico, dove ciascuno stato di base rappresenta un campione del dataset.
- **L'encoding dinamico** (o "dynamic encoding") prevede la rappresentazione dei dati classici come una sovrapposizione di stati di base di un sistema quantistico, dove la sovrapposizione viene modificata dinamicamente in base ai dati di input.




Figura 4.10: Quantum data processing: QML.



Queste tecniche consentono di rappresentare le informazioni quantistiche in modo efficace e di estrarre caratteristiche rilevanti dai dati.

Lo studio ha mostrato che nel ML tradizionale, i dati vengono rappresentati utilizzando vettori di input e output, mentre nel QML, i dati vengono rappresentati utilizzando stati quantistici.

La manipolazione dei qubit può essere utilizzata per effettuare operazioni di elaborazione quantistica durante la fase di preparazione dei dati, introducendo nuovi approcci per la riduzione delle dimensioni, l'elaborazione delle immagini e l'analisi dei grafici.

La revisione condotta ha evidenziato l'esistenza di 2 tipi di preparazione:

- Single-preparation
- Multiple-preparation

La **preparazione singola** (single-preparation) viene utilizzata principalmente nel QML, dove si riferisce alla capacità di lavorare con un singolo esempio di uno stato quantistico sconosciuto, invece di dover creare molte copie dello stesso stato per eseguire le misurazioni. Questo rende l'approccio più efficiente in termini di risorse, ma lo rende anche più complesso in termini di progettazione degli algoritmi e richiede tecniche di elaborazione dati più avanzate.

Al contrario, la **preparazione multipla** (multiple-preparation) viene utilizzata sia nel QML che nel ML tradizionale, ma viene utilizzata per scopi diversi. Nel QML, la preparazione multipla viene utilizzata per ottenere una stima più accurata delle proprietà del sistema, mentre nel machine learning tradizionale viene utilizzata per addestrare i modelli su grandi quantità di dati.

Queste differenze evidenziano come il Quantum Machine Learning non sia solo una trasposizione diretta del machine learning classico in un contesto quantistico, ma impieghi principi e proprietà uniche della meccanica quantistica per manipolare e rappresentare l'informazione in modo innovativo.

## **4.4.2 Addestramento dei modelli nel QML**

Le osservazioni e i risultati successivi sono basati sui documenti indicati nella tabella 4.1.

L'addestramento dei modelli nel contesto del QML richiede approcci specifici per sfruttare la potenza dei computer quantistici.

### **Obiettivo Principale**

L'obiettivo principale del QML è sostituire l'addestramento iterativo con algoritmi quantistici più veloci, ma attualmente, ciò rimane una sfida aperta. Le limitazioni delle macchine quantistiche, come tempi di coerenza brevi e capacità di memoria limitate, influenzano l'addestramento nel QML.

### **Approcci Ibridi e Algoritmi Quantistici**

Il QML può utilizzare approcci ibridi che combinano componenti quantistici e classici per l'addestramento dei modelli. Ad esempio, un approccio ibrido potrebbe utilizzare un algoritmo quantistico per eseguire una selezione preliminare dei campioni di addestramento, riducendo così la quantità di dati da elaborare su una macchina quantistica.

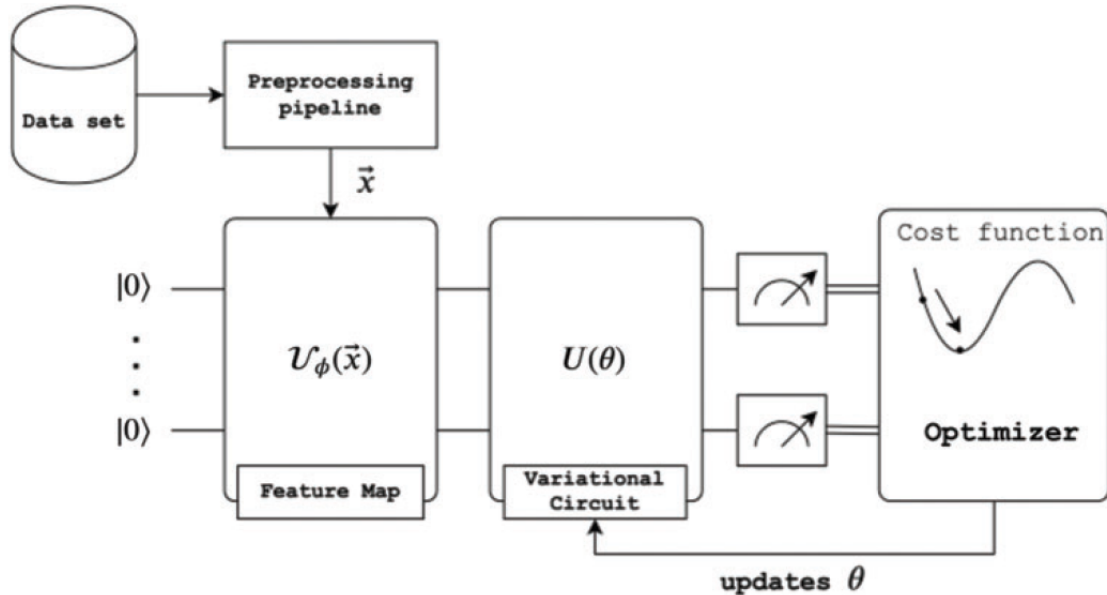
### **Algoritmi di Apprendimento**

Nel QML, vengono utilizzati algoritmi di apprendimento specifici progettati per essere eseguiti su computer quantistici, come il Variational Quantum Classifier (VQC) (Figura 4.11). Questi algoritmi sfruttano le proprietà quantistiche per eseguire operazioni di classificazione e regressione.

### **Complessità Computazionale**

A causa delle limitazioni attuali dei computer quantistici, l'addestramento dei modelli nel QML può essere più complesso e richiedere approcci innovativi per mas-

simizzare l'efficienza e la precisione. Ad esempio, l'utilizzo di tecniche di ottimizzazione quantistica può ridurre il numero di operazioni necessarie per l'addestramento del modello.



**Figura 4.11:** Vista schematica dell'algoritmo VQC.


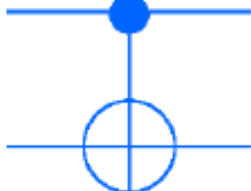


## Sfide nel Mappare i Protocolli di Apprendimento

Nel contesto dell'addestramento dei modelli quantistici, viene evidenziata la sfida nel mappare i protocolli di apprendimento tipici del processo di elaborazione delle informazioni quantistiche. Poiché, le informazioni quantistiche non possono essere aggiornate direttamente, come gli operatori di peso di una rete neurale classica, le strategie di apprendimento devono essere adattate per l'ambiente quantistico.

## Costruzione dei Circuiti Quantistici per l'Addestramento

1. **Porte Logiche Quantistiche:** Nei circuiti quantistici per il QML, vengono utilizzate porte logiche quantistiche (Figura 4.12) come Hadamard e CNOT per eseguire operazioni su qubit, sfruttando le proprietà uniche della meccanica quantistica.
2. **Ansatz Variazionale:** È comune utilizzare un'ansatz variazionale nella costruzione dei circuiti del QML. Questa struttura con parametri variabili si adatta

durante l'addestramento per soddisfare le esigenze specifiche del problema di apprendimento automatico.

Gate	Matrix	Circuit Representation
X	$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$	
CNOT	$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$	
Ry	$\begin{bmatrix} \cos \frac{\theta}{2} & -\sin \frac{\theta}{2} \\ \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{bmatrix}$	
Rot	$\begin{bmatrix} e^{-i(\phi+\omega)/2} \cos \frac{\theta}{2} & -e^{i(\phi-\omega)/2} \sin \frac{\theta}{2} \\ e^{-i(\phi-\omega)/2} \sin \frac{\theta}{2} & e^{i(\phi+\omega)/2} \cos \frac{\theta}{2} \end{bmatrix}$	

**Figura 4.12:** Matrici e Rappresentazioni Circuituali dei Gate X, CNOT, RY e ROT.

## Algoritmi e Tecniche nel QML

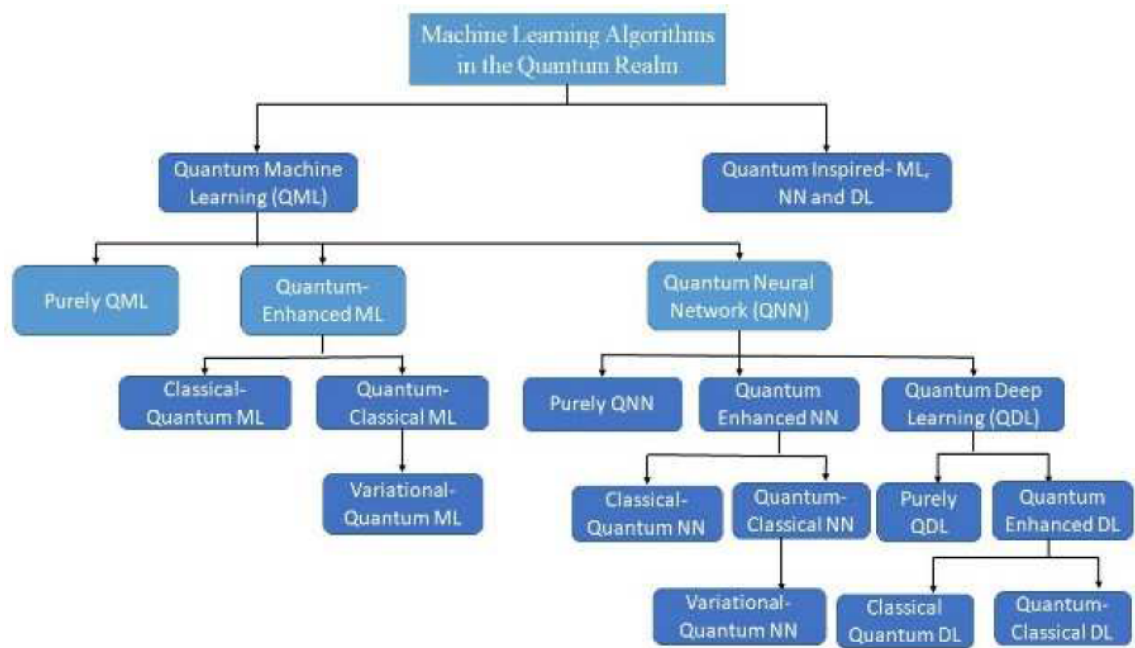
1. **Algoritmi di Quantum Variational:** Gli algoritmi di Quantum Variational, come VQE e QAOA, sono progettati per operare su circuiti quantistici variazionali, ottimizzando i parametri del circuito per minimizzare la funzione di costo.
2. **Algoritmi di Ricerca Quantistica:** Nel QML, l'uso di algoritmi, come l'algoritmo di ricerca quantistica dei minimi globali, sfrutta le proprietà quantistiche per esplorare in modo efficiente lo spazio dei parametri.

La Figura 4.13 mostra la tassonomia degli algoritmi di ML nel regno quantistico, la quale distingue tre classi principali:

1. **Purely QML:** Questa classe comprende gli algoritmi di Machine Learning che sfruttano esclusivamente le capacità dei computer quantistici, senza alcuna componente classica. Questi algoritmi lavorano direttamente su dati quantistici, utilizzando le proprietà come la sovrapposizione e l'entanglement per eseguire calcoli e analisi dei dati.
2. **Quantum-Enhanced ML:** Questi algoritmi combinano le capacità di calcolo quantistico con le tecniche di Machine Learning tradizionali per migliorare le prestazioni dei modelli. Integrando elementi del calcolo quantistico e classico, questi algoritmi mirano a ottenere vantaggi in termini di velocità di elaborazione, gestione dei dati e capacità di apprendimento.
3. **Quantum Neural Network (QNN):** Questa classe di algoritmi sfrutta le proprietà del calcolo quantistico per implementare reti neurali artificiali. I QNN offrono un'alternativa alle reti neurali classiche, consentendo il calcolo parallelo e l'analisi dei dati su sistemi quantistici. Utilizzando qubit e porte quantistiche per rappresentare e manipolare l'informazione all'interno della rete neurale, i QNN promettono una maggiore capacità computazionale e migliori prestazioni. Esistono diverse varianti di QNN, ognuna con un approccio specifico all'implementazione, ma tutte mirano a sfruttare le potenzialità dei computer quantistici nell'ambito del Machine Learning.

### Vantaggi del QML nell'Addestramento dei Modelli

- **Riduzione del Tasso di Perdita:** L'uso del calcolo quantistico può ridurre il tasso di perdita dell'addestramento, offrendo un miglioramento significativo rispetto ai modelli classici.
- **Aumento dell'Accuratezza:** L'addestramento con QML può portare a un aumento dell'accuratezza, superando i risultati ottenuti con il machine learning tradizionale.



**Figura 4.13:** Classification QML algorithms

Queste differenze evidenziano come l'addestramento dei modelli nel QML sia influenzato dalle proprietà uniche della computazione quantistica e dalle tecniche specifiche utilizzate per sfruttarle nell'ambito dell'apprendimento automatico.

### 4.4.3 Valutazione delle prestazioni nel QML

Le osservazioni e i risultati successivi sono basati sui documenti indicati nella tabella 4.1.

La valutazione delle prestazioni dei modelli di QML richiede metriche e approcci specifici, considerando la natura probabilistica e la struttura quantistica dei modelli.

### Limitazioni dell'Algoritmo e delle Risorse Quantistiche

Una delle sfide chiave nella valutazione delle prestazioni dei modelli di QML è rappresentata dalle limitazioni intrinseche dell'algoritmo quantistico. Questo, include la necessità di adattare i vettori delle caratteristiche alle restrizioni dell'hardware quantistico, con un impatto diretto sull'accuratezza delle previsioni.

La valutazione delle prestazioni nei modelli QML è vincolata dalle limitate risorse quantistiche disponibili. La necessità di testare su simulatori o dispositivi quantistici può influenzare la valutazione complessiva.

### Metriche Specifiche per QML

Nel contesto del QML, l'utilizzo di metriche specifiche è cruciale per comprendere l'efficacia dei modelli quantistici. Alcune metriche includono:

- **Fidelità Quantistica:** Misura la precisione con cui il modello quantistico approssima lo stato desiderato.
- **Distanza di Fubini-Study:** Valuta la discrepanza tra gli stati ottenuti e ideali.
- **Errore di Classificazione Quantistica:** Percentuale di esempi di test classificati erroneamente, considerando il rumore quantistico.
- **Precisione Quantistica, Recall e F1-Score:** Metriche specifiche per valutare la precisione e la capacità di richiamare correttamente le istanze positive.

L'utilizzo di metriche specifiche è necessario per valutare la robustezza del modello.

## **Complessità Computazionale e Sensibilità ai Disturbi**

La complessità computazionale nell'esecuzione di algoritmi quantistici e la sensibilità al rumore quantistico sono elementi critici nella valutazione delle prestazioni.

## **Necessità di Benchmark Consolidati**

A differenza del ML tradizionale, il QML manca di benchmark consolidati, complicando la valutazione comparativa. Tale mancanza sottolinea la necessità di sviluppare benchmark universali accettati nel campo del QML.

## **Riduzione del Numero di Campioni e Dimensione dei Campioni**

La tecnica innovativa di località quantistica, che consente la riduzione del numero e delle dimensioni dei campioni di input, introduce una dinamica unica nella valutazione delle prestazioni di QML. Questo aspetto deve essere attentamente considerato per una valutazione completa.

In conclusione, la fase di valutazione delle prestazioni nel QML richiede l'adozione di metriche specifiche e una considerazione attenta delle: limitazioni delle risorse quantistiche, complessità computazionale e sensibilità ai disturbi; al fine di comprendere appieno l'efficacia di questi modelli nel contesto delle sfide uniche presentate dalla computazione quantistica.



#### 4.4.4 Ottimizzazione dei parametri nel QML

Le osservazioni e i risultati successivi sono basati sui documenti indicati nella tabella 4.1.

L'ottimizzazione dei parametri dei modelli quantistici presenta sfide uniche rispetto al Machine Learning tradizionale.

#### Algoritmi di Ottimizzazione

Nel contesto del Quantum Machine Learning (QML), l'ottimizzazione dei parametri impiega algoritmi quantistici specializzati, come l'**annealing quantistico** e l'**algoritmo di ricerca di Grover**. Questi algoritmi capitalizzano sulle proprietà quantistiche per esplorare in modo efficiente lo spazio dei parametri. In contrasto, nel Machine Learning Tradizionale (ML), si fa ampio uso di algoritmi di ottimizzazione classica, come la discesa del gradiente stocastico.

#### Algoritmo di Harrow-Hassidim-Lloyd (HHL)

L'algoritmo HHL, progettato per risolvere sistemi lineari di equazioni, è un esempio di come il QML si differenzi dal ML tradizionale nella fase di ottimizzazione dei parametri. L'HHL, sfruttando le proprietà quantistiche, esegue calcoli più efficienti rispetto agli algoritmi classici per la risoluzione di sistemi lineari, introducendo un approccio quantistico specifico per ottimizzare i parametri.

#### Complessità del Modello

La complessità dei modelli nel QML può superare notevolmente quella dei modelli classici, grazie alla natura quantistica dei dati e dei modelli. Di conseguenza, l'ottimizzazione dei parametri richiede l'implementazione di tecniche avanzate e computazionalmente costose. Nel ML tradizionale, la complessità dei modelli è generalmente gestita in modo più convenzionale.

## **Rumore Quantistico**

La presenza di rumore quantistico costituisce una sfida nell'ottimizzazione dei parametri nel QML. Tecniche di mitigazione degli errori e correzione degli errori quantistici sono essenziali per ridurre gli effetti del rumore. Nel ML tradizionale, la gestione del rumore si basa su approcci classici senza affrontare le sfide specifiche del contesto quantistico.

## **Dimensione Limitata del Dataset**

La dimensione del dataset nel QML può essere limitata dalle attuali capacità di elaborazione dei computer quantistici. Ciò implica che l'ottimizzazione dei parametri potrebbe richiedere l'adozione di tecniche di campionamento efficienti. Nel ML tradizionale, la dimensione del dataset è spesso gestita senza le stesse restrizioni.

## **Complessità dei Circuiti Quantistici**

La complessità dei circuiti quantistici nel QML può crescere rapidamente con il numero di qubit e parametri, introducendo sfide aggiuntive nell'ottimizzazione. Nel ML tradizionale, la complessità dei circuiti non è una considerazione rilevante.

Le differenze nell'ottimizzazione dei parametri tra QML e ML derivano dall'uso di algoritmi quantistici, dalle specifiche sfide legate al rumore e alla complessità dei circuiti nel contesto quantistico. Comprendere queste dinamiche è cruciale per una corretta implementazione e interpretazione delle fasi di ottimizzazione nei rispettivi ambiti.

In sintesi, le differenze ottenute nella pipeline del QML evidenziano l'importanza di adottare approcci e metodologie specifiche per affrontare le sfide introdotte dalla computazione quantistica. La preparazione dei dati, l'addestramento dei modelli, la valutazione delle prestazioni e l'ottimizzazione dei parametri nel contesto del QML richiedono una comprensione approfondita delle caratteristiche uniche della computazione quantistica e delle tecniche quantistiche utilizzate.

---

### Conclusioni e Sviluppi Futuri

---

Il presente lavoro di tesi riporta una Systematic Literature Review sulle principali differenze nell'elaborazione dei dati tra il Quantum Machine Learning (QML) e il Machine Learning tradizionale (ML). L'analisi è stata condotta su un totale di 21 articoli, i quali ci hanno permesso di rispondere in maniera precisa alla domanda di ricerca formulata. Nonostante il QML sia una disciplina emergente, negli ultimi anni si è registrato un notevole interesse da parte di rinomati esperti, consentendo di ottenere risultati di alto livello.

I risultati ottenuti sono stati così organizzati e suddivisi in quattro sezioni chiave:

- Preparazione dei dati
- Addestramento dei modelli
- Valutazione delle prestazioni
- Ottimizzazione dei parametri

Questa suddivisione ha consentito una chiara comprensione delle sfide e delle peculiarità associate a ciascuna fase della pipeline, sia nel contesto quantistico che in quello tradizionale.

In conclusione, questa approfondita analisi ha contribuito a consolidare la nostra comprensione delle dinamiche intrinseche al QML rispetto al ML tradizionale, fornendo un fondamentale contributo in questa promettente area di ricerca.

## 5.1 Punti critici e Direzioni future

Alla fine della revisione della letteratura, è emerso un panorama delle differenze nella pipeline del Quantum Machine Learning (QML) rispetto al Machine Learning tradizionale. Tuttavia, è importante riconoscere che la ricerca nel campo del QML è ancora in evoluzione e presenta alcune lacune da affrontare:

- **Lacune nelle metodologie di valutazione delle prestazioni:** Sebbene siano state proposte alcune metriche per valutare le prestazioni dei modelli di QML, è evidente la necessità di sviluppare ulteriori metodi e approcci per misurare e confrontare l'efficacia dei modelli quantistici rispetto a quelli tradizionali. Le sfide principali risiedono nel considerare l'impatto del rumore quantistico e degli errori nella valutazione delle prestazioni e nella definizione di metriche appropriate per misurare l'accuratezza e l'affidabilità dei modelli QML. Inoltre, la valutazione delle prestazioni dei modelli di QML su problemi reali richiede lo sviluppo di framework e benchmark adeguati per testare l'efficacia e l'efficienza dei modelli.
- **Ottimizzazione dei parametri quantistici** L'ottimizzazione dei parametri dei modelli quantistici è ancora un campo di ricerca in via di sviluppo. Sono state proposte diverse tecniche di ottimizzazione quantistica, come l'algoritmo HHL e l'algoritmo VQE, ma devono ancora essere esplorati nuovi metodi per migliorare l'efficienza e la stabilità dell'ottimizzazione dei parametri nei modelli di QML. Inoltre, l'adattamento delle tecniche di ottimizzazione tradizionali al contesto quantistico rappresenta una sfida significativa da affrontare per cui è necessario sviluppare nuovi algoritmi e strategie di ottimizzazione specificamente progettati per sfruttare al meglio le caratteristiche uniche della computazione quantistica e superare le limitazioni dei computer quantistici attuali.

- **Scalabilità e complessità computazionale** La scalabilità è una delle principali sfide delle implementazioni pratiche del QML. Attualmente, i computer quantistici disponibili sono limitati nel numero di qubit e nel tempo di coerenza. Pertanto, è necessario sviluppare strategie e algoritmi che affrontino la complessità computazionale e rendano QML applicabile a problemi di dimensioni reali. La ricerca sulle tecniche di riduzione della dimensionalità e la gestione degli errori quantistici sono aree chiave per rendere il QML scalabile e praticamente utilizzabile. Inoltre, è necessario esplorare nuovi paradigmi di programmazione e infrastrutture hardware che consentano di superare le limitazioni attuali e di realizzare sistemi quantistici più potenti e scalabili.

Sebbene sia ancora nelle sue fasi iniziali, il QML ha il potenziale per sovraperformare il ML tradizionale in vari domini, offrendo maggiore potenza computazionale, migliore analisi dei dati e maggiore robustezza. Mentre la tecnologia quantistica continua ad avanzare, il QML è pronto a rivoluzionare diversi settori, aprendo la strada a una nuova era di innovazione guidata dall'intelligenza artificiale.

---

## Bibliografia

---

- [1] M. Ivaldi, *Introduzione al Quantum Computing*, 2021. (Citato a pagina 1)
- [2] MarketDigits, “Quantum computing market...” 2023, <https://www.marketdigits.com/quantum-computing-market>. (Citato a pagina 2)
- [3] M. De Stefano, F. Pecorelli, D. Di Nucci, F. Palomba, and A. De Lucia, “Software engineering for quantum programming: How far are we?” *Journal of Systems and Software*, vol. 190, 2022. (Citato a pagina 5)
- [4] P. Kaye, R. Laflamme, and M. Mosca, *An Introduction to Quantum Computing*. USA: Oxford University Press, Inc., 2007. (Citato a pagina 5)
- [5] E. Buratin. Entanglement quantistico. <https://www.geopop.it/una-spiegazione-semplce-dellentanglement-quantistico/>. (Citato a pagina 6)
- [6] T. Bio. (2023) Svelare l’entanglement quantistico per l’informatica pratica. <https://www.tomorrow.bio/it/post/svelare-l-entanglement-quantistico-per-l-informatica-pratica-2023-09-5137837172-quantum>. (Citato a pagina 6)
- [7] Oracle Corporation. What is machine learning? <https://www.oracle.com/it/artificial-intelligence/machine-learning/what-is-machine-learning/>. (Citato a pagina 7)
- [8] B. Mahesh, “Machine learning algorithms -a review,” 01 2019. (Citato a pagina 8)

- 
- [9] V. Nasteski, "An overview of the supervised machine learning methods," *HORIZONS.B*, vol. 4, pp. 51–62, 12 2017. (Citato a pagina 8)
- [10] H. Hapke and C. Nelson, *Building Machine Learning Pipelines: Automating Model Life Cycles with TensorFlow*. O'Reilly Media, Incorporated, 2020, <https://books.google.it/books?id=8hpPzQEACAAJ>. (Citato a pagina 9)
- [11] Daivi. Machine learning pipeline architecture. [https://www.projectpro.io/article/machine-learning-pipeline-architecture/567#mcetoc\\_1fso24nr2g](https://www.projectpro.io/article/machine-learning-pipeline-architecture/567#mcetoc_1fso24nr2g). (Citato a pagina 10)
- [12] M. Schuld, I. Sinayskiy, and F. Petruccione, "An introduction to quantum machine learning," *Contemporary Physics*, vol. 56, no. 2, p. 172–185, 2014, <http://dx.doi.org/10.1080/00107514.2014.964942>. (Citato a pagina 13)
- [13] P. Sandonnini. (2023) L'apprendimento automatico quantistico (qml). <https://www.ai4business.it/quantum-computing/lapprendimento-automatico-quantistico-qml-cose-cosa-permette-di-fare/>. (Citato a pagina 13)
- [14] R. Campagnola. (2021) Gli algoritmi quantistici. <https://www.redhotcyber.com/post/gli-algoritmi-quantistici-lezione-4/>. (Citato a pagina 14)
- [15] D. Deutsch and R. Jozsa, "Rapid solution of problems by quantum computation," 1992. (Citato a pagina 14)
- [16] P. Shor, "Algorithms for quantum computation: discrete logarithms and factoring," 1994. (Citato a pagina 14)
- [17] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," no. EBSE 2007-001, 2007, <http://www.dur.ac.uk/ebse/resources/Systematic-reviews-5-8.pdf>. (Citato a pagina 18)
- [18] M. Garo. (2020) Systematic review: 10 passi per orientarsi ed eseguirla al meglio. <https://www.mathsly.it/wordpress/systematic-review-10-passi-per-orientarsi-ed-eseguirla-al-meglio/>. (Citato a pagina 18)



## **Elenco delle fonti**

- S01 - Y. Deville, Y. Deville, and A. Deville, "New Single-Preparation Methods for Unsupervised Quantum Machine Learning Problems," *IEEE Transactions on Quantum Engineering*, 2021.
- S02 - Y. Wang, C. Chen, and W. Huang, "Design of quantum filter for hybrid quantum-classical convolutional neural networks," *2021 International Conference on Information Technology and Biomedical Engineering (ICITBE)*, 2021.
- S03 - D. Sierra-Sosa, M. Telahun, M. Telahun, A. Elmaghraby, and A. Elmaghraby, "TensorFlow Quantum: Impacts of Quantum State Preparation on Quantum Machine Learning Performance," *IEEE International Conference on Image Processing (ICIP)*, 2020.
- S04 - T. Gabor, L. Sünkel, F. Ritz, T. Phan, L. Belzner, C. Roch, S. Feld, C. Linnhoff-Popien, C. Linnhoff-Popien, and C. Linnhoff-Popien, "The Holy Grail of Quantum Artificial Intelligence: Major challenges in Accelerating the Machine Learning Pipeline," *International Conference on Software Engineering*, 2020.
- S05 - W. Jiang, J. Xiong, J. Xiong, J. Xiong, and Y. Shi, "When Machine Learning Meets Quantum Computers: A Case Study," *arXiv: Quantum Physics*, 2020.
- S06 - E. Perrier, "Quantum Fair Machine Learning," *AAAI/ACM Conference on AI, Ethics, and Society*, 2021.
- S07 - R. Jia, G. Yang, M. Nie, Y.-h. Liu, and M. Zhang, "Automatic Optimization of Variational Quantum Algorithm-Based Classifiers," *International Conference on Artificial Intelligence and Pattern Recognition*, 2022.
- S08 - D. Sierra-Sosa, J. D. Arcila-Moreno, B. Garcia-Zapirain, A. Elmaghraby, and A. Elmaghraby, "Diabetes Type 2: PoincarData Preprocessing for Quantum Machine Learning," *Cmc-computers Materials Continua*,
- S09 - M. T. Kakiz, E. Güler, T. Çavdar, and B. Sanal, "Binary Classification with Variational Quantum Circuit," *2023 Innovations in Intelligent Systems and Applications Conference (ASYU)*, 2023.

- S10 - S. Rani, P. K. Pareek, J. Kaur, M. Chauhan, and P. Bhambri, "Quantum Machine Learning in Healthcare: Developments and Challenges," 2023 IEEE International Conference on Integrated Circuits and Communication Systems (ICICACS), 2023.
- S11 - D. Maheshwari, D. Sierra-Sosa, and B. Garcia-Zapirain, "Variational Quantum Classifier for Binary Classification: Real vs Synthetic Dataset," IEEE Transactions on Neural Networks and Learning Systems, 2021.
- S12 - H. Xiong, X. Duan, Y. Yu, J. Zhang, and H. Yin, "Image classification based on quantum machine learning," 2023 5th International Conference on Intelligent Control, Measurement and Signal Processing (ICMSP), 2023.
- S13 - P. Kuppusamy, N. Y. Kumar, J. Dontireddy, and C. Iwendi, "Quantum Computing and Quantum Machine Learning Classification – A Survey," 2022 IEEE 4th International Conference on Cybernetics, Cognition and Machine Learning Applications (ICCCMLA), 2022.
- S14 - B. Saju, M. K. Gopal, B. Nithya, V. Asha, and V. Kumar, "Analysis on Role of Quantum Computing in Machine Learning," International Conference on Cognitive Computing and Information Processing, 2022.
- S15 - R. Das, "Quantum Machine Learning based Computer Aided Diagnosis for Skin Cancer Detection: A Statistical Performance Analysis over Classical Approach," 2022 International Conference on Trends in Quantum Computing and Emerging Business Technologies (TQCEBT), 2022.
- S16 - Y.-F. Yang and M. Sun, "Hybrid Quantum-Classical Machine Learning for Lithography Hotspot Detection," Advanced Semiconductor Manufacturing Conference, 2022.
- S17 - E. Zardini, E. Blanzieri, and D. Pastorello, "Implementation and empirical evaluation of a quantum machine learning pipeline for local classification," PLoS ONE, 2022.
- S18 - T. Dyer, "Introduction to quantum machine learning," Journal of Machine Learning Research, vol. 1, pp. 1–48, 2021.

- S19 - T. M. Khan and A. Robles-Kelly, "Machine Learning: Quantum vs Classical," IEEE 2nd International Conference on Mobile Networks and Wireless Communications (ICMNBC), 2020.
- S20 - J. Biamonte, P. Wittek, N. Pancotti, P. Rebentrost, N. Wiebe, S. Lloyd, and S. Lloyd, "Quantum machine learning," *Nature*, 2017.
- S21 - R. K. Nath, H. Thapliyal, T. S. Humble, and T. S. Humble, "A Review of Machine Learning Classification Using Quantum Annealing for Real-World Applications," *SN Computer Science*, 2021.

---

## Ringraziamenti

---

Desidero ringraziare il professore Andrea De Lucia e il dottor Fabiano Pecorelli per avermi guidato durante la realizzazione dell'intera tesi e dato la possibilità di partecipare a questo affascinante progetto di ricerca. Inoltre, li ringrazio per avermi consigliato di avvicinarmi ad un emergente disciplina, capace di suscitare in me un forte interesse.

Desidero ringraziare la mia famiglia per tutto quello che hanno fatto per me. In questi anni sono stati fondamentali; giorno dopo giorno, mi hanno motivato con i loro fantastici modi sempre di più e incitato a perseguire i miei obiettivi oltre ogni difficoltà. Se ora sono qui, lo devo anche a voi. **Grazie.**

Un grazie speciale va anche ai miei nipotini, i quali nei momenti di pausa hanno sempre saputo risollevare il mio umore. **Grazie.**

In questo giorno molto importante, desidero ringraziare una persona speciale che mi ha aiutato ad affrontare molte difficoltà presenti in questi anni. Non sei stata una semplice fidanzata, ma sei stata una vera e propria collega. Mi hai supportato e sopportato nei momenti più bui, e io te ne sarò per sempre grato. Grazie di avermi messo **sempre** al primo posto. Non so se ce l'avrei fatta senza di te. **Grazie.**

---

Infine, desidero ringraziare il mio collega, nonché amico Alex, il quale con mille risate e mille paranoie ha reso meravigliosi questi anni. Non dimenticherò mai le tante notti in bianco e i tanti progetti fatti insieme. **Grazie**, Menzognaman.